Agente de calidad del aire del Valle de Aburrá

INFORME FINAL · SI3003 – INTELIGENCIA ARTIFICIAL

Universidad EAFIT · Escuela de Ciencias Aplicadas e Ingeniería · Periodo 2026-1

Integrantes: Leidy Gallo Vargas · Valentina Aguilar Correa · Sara Zuluaga Trujillo

Repositorio: https://github.com/sazt19/proyecto_intro_IA | Aplicación: https://calidadairevalle.streamlit.app/

Resumen

Se desarrolló un prototipo académico para interpretar concentraciones de material particulado fino (PM2.5) en el Valle de Aburrá. El sistema integra observaciones reales de SIATA, variables meteorológicas históricas, una regresión logística multinomial implementada con NumPy y un agente conversacional con herramientas y recuperación documental (RAG). La aplicación en Streamlit permite consultar estaciones, explorar series temporales, estimar la categoría del día siguiente y obtener explicaciones respaldadas por fuentes. En una prueba temporal de 1.816 observaciones estación-día, el modelo obtuvo accuracy de 0,769 y F1-macro de 0,674. La evaluación reportada del agente registró 13/13 selecciones correctas de herramientas y 12/12 respuestas pertinentes con cita.

1. Problema, objetivo y alcance

Los datos de calidad del aire son públicos, pero interpretar sus unidades, categorías y consecuencias no resulta sencillo para el público general. El objetivo es ofrecer una interfaz única que transforme registros históricos de PM2.5 en información comprensible y que combine predicción estadística, consulta normativa y diálogo en lenguaje natural. El prototipo no efectúa vigilancia en tiempo real ni sustituye las decisiones oficiales de gestión ambiental o las recomendaciones médicas.

2. Datos y preparación

Se emplearon registros horarios de PM2.5 de 16 estaciones de SIATA entre julio de 2023 y julio de 2024, junto con precipitación, viento máximo y humedad diaria procedentes de Open-Meteo (reanálisis ERA5). Se eliminaron valores -9999, negativos, superiores a 500 µg/m³ y estaciones fuera de operación. Los promedios diarios se conservaron con al menos 18 horas válidas (75 % de cobertura): 5.728 registros estación-día.

Fuente	Variables / finalidad
SIATA	PM2.5 horario; códigos y ubicación de las estaciones
Open-Meteo / ERA5	Lluvia, viento máximo y humedad diaria como covariables meteorológicas

El promedio diario de PM2.5 fue de 18,7 µg/m³. Marzo de 2024 registró el mayor promedio mensual (31,3 µg/m³) y 98 días-estación por encima de 37 µg/m³. CEN-TRAF presentó el promedio más alto entre estaciones: 26,4 µg/m³. Los datos procesados están incluidos en data/processed/ como alternativa a la descarga en línea.

3. Modelo clásico: regresión logística multinomial

Se formuló una clasificación supervisada para anticipar la categoría de PM2.5 del día siguiente: buena (hasta 12 µg/m³), aceptable (más de 12 y hasta 37) y dañina (más de 37). La última clase agrupa niveles de mayor riesgo debido a su baja frecuencia. El modelo softmax está implementado por el equipo en src/model.py con NumPy; no se delega el ajuste a una biblioteca de estimadores.

3.1. Variables y entrenamiento

La entrada contiene PM2.5 actual y del día anterior, promedio móvil de tres días, tendencia diaria, precipitación, viento máximo, humedad, indicador de fin de semana y mes codificado mediante seno/coseno. Antes del entrenamiento se estandarizan variables. El ajuste usa descenso de gradiente, regularización L2 y ponderaciones parciales inversas a la frecuencia de las clases. La probabilidad de clase k se calcula como:

$P(y = k \mid x) = \exp(x \cdot W_k + b_k) / \Sigma_j \exp(x \cdot W_j + b_j)$.

El conjunto se divide cronológicamente: entrenamiento anterior al 1 de abril de 2024 y evaluación desde esa fecha hasta julio de 2024. Esta separación reduce el riesgo de evaluar sobre días anteriores al entrenamiento y se aproxima mejor al uso predictivo que una partición aleatoria.

3.2. Comparación frente a líneas base

Método	Accuracy	F1-macro	F1 clase dañina
Regresión logística propia	0,769	0,674	0,52
Persistencia (mañana = hoy)	0,764	0,689	0,62
Clase mayoritaria	0,692	0,273	0,00

La regresión logística supera a la persistencia en accuracy por 0,005 puntos absolutos (0,5 puntos porcentuales), pero queda 0,015 por debajo en F1-macro y también tiene menor F1 para la clase dañina. Por tanto, no es correcto afirmar una superioridad global sobre la persistencia. Su aporte principal al agente es producir probabilidades por clase, útiles para comunicar incertidumbre, en lugar de entregar solo una etiqueta.

3.3. Interpretación experimental

La fuerte desproporción de clases condiciona los resultados: 1.021 registros buenos, 4.520 aceptables y 187 dañinos en el conjunto procesado. En especial, los episodios de contaminación elevada son poco frecuentes y difíciles de anticipar. Por ello se reportan F1-macro y F1 de la clase dañina, además de accuracy, y el dashboard expone matrices de confusión para examinar los tipos de error.

4. Agente conversacional y recuperación documental

La aplicación utiliza un LLM mediante NVIDIA NIM, con un endpoint compatible con la API de OpenAI. El modelo principal documentado es nvidia/nemotron-3.5-lightning-30b-a3b. En src/agent.py se implementó un ciclo agéntico manual: el LLM interpreta la pregunta, decide qué herramienta invocar, recibe el resultado como observación y genera la respuesta. Se limitan las iteraciones a T_max = 5; las excepciones de herramientas se devuelven como observaciones para evitar que un fallo interrumpa la aplicación.

4.1. Herramientas disponibles

Herramienta	Propósito
list_stations	Enumerar estaciones consultables
get_pm25(estacion, fecha)	Consultar medida histórica diaria y clasificación ICA
station_summary(estacion)	Resumir mínimo, máximo, promedio y excedencias
predict_tomorrow(estacion, fecha)	Invocar el modelo propio y entregar probabilidades de mañana
search_docs(query)	Recuperar fragmentos normativos y recomendaciones para citar

La integración entre ambas partes del curso es funcional: el agente consulta la herramienta predict_tomorrow, que usa la regresión logística propia. Posteriormente puede relacionar la estimación con el contenido normativo recuperado. El sistema indica que su información es histórica; para preguntas sin respaldo suficiente evita inventar valores y utiliza un mensaje de rechazo.

4.2. Diseño del RAG

El corpus está almacenado en docs/fuentes.json y contiene 19 fragmentos preparados a partir de la Resolución colombiana 2254 de 2017, directrices OMS 2021, información del AMVA/POECA y estadísticas del proyecto. El buscador de src/rag.py normaliza el texto y calcula TF-IDF con unigramas y bigramas; la similitud coseno permite ordenar los fragmentos (hasta cuatro por defecto). Cada resultado conserva título, sección y URL para fundamentar la respuesta del LLM.

Esta estrategia implementa recuperación aumentada, aunque no emplea embeddings neuronales ni una base vectorial especializada. Se eligió por su bajo costo computacional y sencillez para un corpus pequeño. Como contrapartida, la búsqueda basada en coincidencias léxicas puede omitir textos semánticamente relacionados cuando las palabras de la consulta difieren.

5. Dashboard e interacción

La interfaz se construyó en Streamlit y se organiza en tres pestañas. Dashboard ofrece mapa de estaciones con categoría ICA, serie temporal con franjas de calidad y referencia diaria de 37 µg/m³, y predicción del día siguiente. Agente habilita conversación y fuentes. Modelo presenta métricas y matrices de confusión frente a líneas base. Los controles permiten elegir estación, fecha y rango de visualización; el proyecto incluye instrucciones reproducibles y datos locales preprocesados.

6. Resultados de la evaluación del agente

El script src/evaluate.py evalúa 13 consultas fijas que abarcan datos medidos, predicción, normativa, consultas combinadas, fecha fuera del periodo y pregunta ajena al dominio. Según docs/evaluacion_agente.md, el agente seleccionó las herramientas esperadas en 13 de 13 casos (100 %) y citó fuente en 12 de 12 casos aplicables (100 %); la pregunta fuera de tema se excluye de la segunda proporción.

Tipo de prueba	Ejemplo / resultado documentado
Consulta histórica	PM2.5 de Bello en fecha específica: get_pm25
Predicción	Calidad del aire del día siguiente: predict_tomorrow
Normativa	Límite colombiano de PM2.5: search_docs
Consulta compuesta	Barbosa hoy y mañana: get_pm25 + predict_tomorrow
Manejo de límites	Fecha fuera de rango y pregunta fuera de tema: respuestas restringidas

El éxito en selección de herramientas y presencia de citas no implica exactitud factual perfecta. Se detectó una fecha desplazada un día en una predicción (12 en vez de 11 de abril) y una respuesta que incluyó una negativa innecesaria tras una explicación válida. Estas fallas muestran la necesidad de verificar la coherencia final del texto generado.

7. Limitaciones y posibles mejoras

El conjunto SIATA es histórico (julio de 2023 a julio de 2024), por lo que “hoy” corresponde al último día registrado y no al día actual. Solo hubo dos días superiores a 55 µg/m³, situación que motivó agrupar categorías altas y limita la evaluación de episodios críticos. Los datos meteorológicos provienen de reanálisis y no de sensores meteorológicos en cada estación. La persistencia mantiene mejor F1-macro que el modelo propio. El RAG utiliza 19 resúmenes y puede perder matices de los documentos originales; el LLM, además, puede cometer errores de interpretación y depende de la disponibilidad del servicio NVIDIA.

Como trabajo futuro se propone ampliar el periodo de datos, validar con nuevos años y estaciones, mejorar el manejo del desbalance de clases, comparar RAG léxico con recuperación semántica y automatizar verificaciones de fechas, unidades y citas antes de presentar respuestas.

8. Reproducibilidad y uso responsable de IA

El repositorio incluye requirements.txt, instrucciones de instalación, archivos procesados y scripts para reentrenamiento y evaluación; la ejecución local parte de streamlit run app.py. El chat requiere credencial NVIDIA_API_KEY, gestionada fuera del repositorio. Según docs/declaracion_ia.md, se utilizó Claude Code como apoyo a escritura y revisión de código y documentación, y NVIDIA NIM como motor del agente. El equipo declara haber diseñado, revisado y probado los componentes. Es una herramienta académica y no un servicio de consejo médico ni una fuente de alertas oficiales.

Referencias y materiales de verificación

Repositorio y código: https://github.com/sazt19/proyecto_intro_IA · Evaluación: docs/evaluacion_agente.md · Declaración: docs/declaracion_ia.md · SIATA: https://siata.gov.co · Open-Meteo: https://open-meteo.com · Resolución 2254 de 2017 y OMS (2021): fuentes identificadas en docs/fuentes.json.